

Análise exploratória de vieses de representação em imagens geradas por IA: uma abordagem quantitativa com Visão Computacional e CLIP

Kauan Henrick Teixeira da Silva

Profa. Dra. Raquel Marcia Müller (Orientadora)
Prof. Dr. Jorge Marques Prates (Coorientador)

Análise exploratória de vieses de representação em imagens geradas por IA: uma abordagem quantitativa com Visão Computacional e CLIP

Kauan Henrick Teixeira da Silva

Este exemplar corresponde à versão provisória da estrutura textual do Trabalho de Conclusão de Curso, apresentada para acompanhamento da disciplina Projeto Final de Curso. O texto organiza a introdução, o referencial teórico, a metodologia, a estrutura prevista dos resultados e as referências bibliográficas do projeto.

Dourados, 25 de julho de 2026

Profa. Dra. Raquel Marcia Müller (Orientadora)
Prof. Dr. Jorge Marques Prates (Coorientador)

Análise exploratória de vieses de representação em imagens geradas por IA: uma abordagem quantitativa com Visão Computacional e CLIP

Kauan Henrick Teixeira da Silva

Julho de 2026

Orientação:

Profa. Dra. Raquel Marcia Müller (Orientadora)
Área de Computação - UEMS

Prof. Dr. Jorge Marques Prates (Coorientador)
Área de Computação - UNESP

Dedico este trabalho primeiramente aos meus pais, por todo o amor, incentivo e apoio incondicional que foram a base para cada passo desta jornada acadêmica.

À minha namorada, pela paciência, carinho e por ter caminhado ao meu lado desde o início da graduação, tornando tudo mais leve.
Aos meus orientadores, pela direção rigorosa e apoio indispensável para a conversão de uma pesquisa exploratória em um artefato científico sólido.

Modelos generativos texto-imagem podem repetir padrões de representação presentes em seus dados de treinamento. Este trabalho desenvolve uma análise aplicada, quantitativa e exploratória de 64 imagens sintéticas de ambientes universitários, produzidas por quatro sistemas a partir de *prompts* neutros e inclusivos. O BiasAuditFW organiza o processamento em duas unidades. DeepFace com RetinaFace produz previsões no nível de cada rosto detectado, enquanto CLIP estima, uma vez por imagem, margens de diversidade racial percebida e de diversidade de apresentação de gênero. Os escores CLIP resultam da comparação entre protótipos textuais de diversidade e homogeneidade, com normalização L2 explícita. A detecção facial será confrontada com caixas anotadas por dois avaliadores. As previsões de atributos também serão comparadas com FairFace como referência secundária, sem tratar os classificadores como fontes de identidade demográfica. Mann–Whitney e Wilcoxon serão aplicados separadamente às duas margens, sempre no nível da imagem e com correção de Holm. A interpretação do Efeito Patchwork dependerá da convergência entre a baseline humana, os escores semânticos e a composição facial.

Palavras-chave: análise de viés; IA generativa; visão computacional; CLIP; diversidade percebida; representação demográfica.

Text-to-image generative models may reproduce representational patterns present in their training data. This work develops an applied, quantitative, and exploratory analysis of 64 synthetic images depicting university environments, generated by four systems from neutral and inclusive prompts. BiasAuditFW separates processing into two observational units. DeepFace with RetinaFace produces predictions for each detected face, whereas CLIP estimates, once per image, perceived racial diversity and gender-presentation diversity margins. The CLIP scores compare textual prototypes of diversity and homogeneity using explicit L2 normalization. Face detection will be evaluated against bounding boxes annotated by two evaluators. Attribute predictions will also be compared with FairFace as a secondary reference, without treating either classifier as a source of demographic identity. Mann–Whitney and Wilcoxon tests will be applied separately to both margins at image level, with Holm correction. The Patchwork Effect will be discussed only if human ratings, semantic scores, and facial composition provide converging evidence.

Keywords: bias analysis; generative AI; computer vision; CLIP; perceived diversity; demographic representation.

Sumário

1	Introdução	18
1.1	Motivação e justificativa	18
1.2	Problema de pesquisa	19
1.3	Objetivos	19
1.4	Classificação e síntese metodológica	19
1.5	Organização dos capítulos	20
2	Trabalhos relacionados	21
2.1	Viés em modelos texto-imagem	21
2.2	Análise quantitativa de representação	21
2.3	DeepFace, FairFace e categorias demográficas	22
2.4	CLIP e protótipos textuais	22
2.5	Sul Global e Efeito Patchwork	22
3	Metodologia	24
3.1	Natureza e delineamento da pesquisa	24
3.2	Corpus, manifesto e baseline humana	24
3.3	Ambiente e fluxo de execução	24
3.4	Deteção e predição de atributos	25
3.5	Escores de diversidade com CLIP	25
3.6	Ground Truth da deteção facial	26
3.7	Baseline humana e pseudo-oráculo	26
3.8	Análise estatística	27
3.9	Reprodutibilidade e artefatos	27
4	Resultados e discussão	28
4.1	Cobertura e integridade do corpus	28
4.2	Desempenho do detector	28
4.3	Baseline humana e pseudo-oráculo	28

4.4	Composição facial	29
4.5	Diversidade semântica no nível da imagem	29
4.6	Comparação entre prompts	29
4.7	Efeito Patchwork e ameaças à validade	29
5	Conclusão	30
	Referências Bibliográficas	32

Lista de Siglas

Lista de Figuras

Lista de Tabelas

Introdução

Modelos texto-imagem são usados em atividades de comunicação visual e produção de conteúdo. Embora consigam gerar cenas plausíveis, esses sistemas também podem repetir associações presentes nos dados de treinamento. Quando uma cena inclui pessoas, atender ao tema geral do *prompt* não garante diversidade na representação.

Este trabalho analisa imagens sintéticas de ambientes universitários. O foco está em duas dimensões observáveis: diversidade racial percebida e diversidade de apresentação de gênero. A expressão Efeito Patchwork descreve uma hipótese interpretativa para a presença de sinais pontuais de inclusão sem mudança consistente no conjunto das imagens. Essa leitura só será considerada se as avaliações humanas, os escores semânticos e a composição facial apontarem na mesma direção.

1.1 Motivação e justificativa

A pesquisa começou durante um intercâmbio acadêmico na Universidad Nacional de Colombia. Naquele período, um estudo sobre comunicação visual universitária comparou 64 imagens produzidas por DALL-E, Midjourney, Whisk e NanoBanana. Duas pessoas avaliaram diversidade racial, representação de gênero, adequação cultural, representação corporal e qualidade visual. O artigo e os dados foram publicados por [Silva et al. \(2026\)](#).

O TCC retoma o mesmo corpus para investigar quanto dessa avaliação pode ser aproximado por um procedimento computacional verificável. A adequação cultural permanece relevante para explicar a origem do problema, mas não é mais tratada como uma categoria CLIP. A América Latina reúne populações e histórias distintas; uma oposição textual entre “latino-americano” e “não latino-americano” reduziria essa heterogeneidade a um rótulo visual pouco defensável.

A literatura registra estereótipos demográficos e culturais em modelos texto-imagem (BIRHANE; PRABHU; KAHSEMBWE, 2021; BIANCHI et al., 2023; SCHNEIDER; HAGEN-DORFF, 2025). Estudos sobre o Sul Global também relatam representações genéricas, combinações inadequadas de referências e baixa fidelidade cultural (MIM et al., 2024; HALL et al., 2024; ZHANG et al., 2024). Nesse contexto, o BiasAuditFW procura tornar explícitas as unidades de análise, os erros do detector e os limites dos classificadores utilizados.

1.2 Problema de pesquisa

O problema é formulado pela seguinte pergunta: *prompts* inclusivos alteram, de forma mensurável, a diversidade racial percebida e a diversidade de apresentação de gênero das imagens, quando comparados a *prompts* neutros?

Há duas hipóteses primárias, uma para cada margem CLIP. Em cada dimensão, a hipótese nula estabelece que não há deslocamento entre as distribuições dos grupos neutro e inclusivo; a hipótese alternativa estabelece que as distribuições diferem. Um resultado com $p \geq 0,05$ será descrito como evidência insuficiente para rejeitar a hipótese nula. Isso não permite concluir que os grupos são iguais.

1.3 Objetivos

O objetivo geral é desenvolver e avaliar um *framework* para análise quantitativa e exploratória de vieses de representação em imagens geradas por IA.

Os objetivos específicos são:

- organizar o corpus em unidades de imagem e de rosto;
- processar imagens em estruturas de diretório arbitrárias, com metadados fornecidos por manifesto;
- detectar todos os rostos com RetinaFace e registrar as predições do DeepFace;
- calcular duas margens CLIP de diversidade percebida com normalização L2;
- medir o desempenho do detector com Ground Truth humano;
- comparar DeepFace com FairFace como referência secundária;
- comparar *prompts* neutros e inclusivos sem pseudorreplcação.

1.4 Classificação e síntese metodológica

A pesquisa é aplicada, com abordagem quantitativa e objetivo exploratório. O delineamento é comparativo. As imagens são agrupadas por tipo de *prompt* e modelo gerador, mas o estudo não pretende explicar causalmente o funcionamento interno desses modelos.

DeepFace produz dados no nível do rosto; CLIP produz dados no nível da imagem. Mann–Whitney compara os grupos a partir de uma observação por imagem, separadamente para as duas margens. Wilcoxon compara imagens do mesmo modelo e cenário como análise de sensibilidade.

1.5 Organização dos capítulos

O Capítulo 2 apresenta os trabalhos relacionados. O Capítulo 3 descreve o corpus, o pipeline, o Ground Truth e os testes. O Capítulo 4 organiza os resultados por unidade de análise. O Capítulo 5 retoma os objetivos e os limites do estudo.

Trabalhos relacionados

2.1 Viés em modelos texto-imagem

Modelos generativos aprendem associações visuais a partir de grandes bases multimodais. Essas bases podem conter hierarquias raciais, misoginia e categorias sociais inadequadas (BIRHANE; PRABHU; KAHEMBWE, 2021). As imagens geradas, por consequência, podem apresentar maior homogeneidade que os contextos que pretendem representar (BIANCHI et al., 2023). Filtros de segurança também não eliminam, por si sós, representações desproporcionais (SCHNEIDER; HAGENDORFF, 2025).

No contexto universitário, Silva et al. (2026) compararam quatro geradores com uma rubrica humana de diversidade racial, representação de gênero, adequação cultural, representação corporal e qualidade visual. Esse estudo fornece o corpus e a baseline humana desta pesquisa. A etapa computacional não substitui o julgamento dos avaliadores; ela permite examinar quais dimensões apresentam associação com medidas automáticas e onde essa aproximação falha.

2.2 Análise quantitativa de representação

Métricas quantitativas ajudam a repetir comparações entre modelos e condições de geração (VICE et al., 2025). Ainda assim, ferramentas automáticas podem deixar de captar formas de viés percebidas por pessoas (LYU et al., 2025). Os valores produzidos pelo BiasAuditFW são, portanto, indicadores operacionais. Sua interpretação depende dos erros de detecção, da concordância entre modelos e da baseline humana.

2.3 DeepFace, FairFace e categorias demográficas

DeepFace reúne detectores faciais e modelos de análise de atributos em uma interface Python (SERENGIL; OZPINAR, 2026). Neste trabalho, RetinaFace localiza as faces e DeepFace retorna categorias de raça e gênero acompanhadas de confiança. Essas saídas descrevem a decisão do classificador sobre uma face sintética. Elas não correspondem à identidade de uma pessoa.

FairFace foi proposto com um conjunto facial mais balanceado entre sete grupos raciais, além de gênero e idade (KARKKAINEN; JOO, 2021). O modelo atua aqui como pseudo-oráculo, isto é, uma referência secundária para medir concordância com DeepFace. Os dois sistemas possuem taxonomias e vieses próprios; concordância entre eles não constitui Ground Truth demográfico.

O Censo Demográfico brasileiro registra cor ou raça a partir da declaração do informante (Instituto Brasileiro de Geografia e Estatística, 2023). Suas categorias ajudam a contextualizar a diversidade da população, mas não formam uma taxonomia de traços faciais. O pipeline não estima nacionalidade, ancestralidade, miscigenação ou sexo biológico. A expressão “aparência racializada” é usada para marcar essa diferença entre percepção visual e identidade social.

2.4 CLIP e protótipos textuais

CLIP projeta imagens e textos em um espaço vetorial compartilhado, o que permite comparar uma imagem com descrições sem treinamento específico para o corpus (RADFORD et al., 2021). O desempenho *zero-shot* é sensível à formulação das frases; o trabalho original usa variações de *prompt* e agregação de classificadores textuais. Por esse motivo, cada conceito do BiasAuditFW é representado por três frases, e não por uma única âncora.

O módulo contrasta diversidade e homogeneidade em duas dimensões: aparência racializada e apresentação de gênero. O resultado é um alinhamento semântico global da imagem. Ele não conta pessoas nem estima proporções. Essa cautela é necessária porque o CLIP original apresenta limitações em tarefas de contagem e composição (PAISS et al., 2023).

Modelos visão-linguagem também podem herdar vieses dos dados de treinamento (SAHILI; PATRAS; PURVER, 2025). A comparação com as notas humanas de diversidade racial e representação de gênero ajuda a verificar se as margens se relacionam com o que os avaliadores perceberam, sem transformar correlação em validade universal.

2.5 Sul Global e Efeito Patchwork

Avaliações geográficas mostram que modelos texto-imagem não representam todos os contextos com a mesma qualidade (HALL et al., 2024). No Sul Global, essas ferramentas podem repetir repertórios visuais externos ou combinar referências locais de modo inadequado (MIM et al., 2024; REGE et al., 2025; ZHANG et al., 2024).

A adequação cultural, investigada no artigo anterior, continua sendo o contexto histórico do TCC. No novo pipeline, porém, o Efeito Patchwork é formulado de maneira mais restrita: inclusão visual pontual sem aumento consistente das duas dimensões de diversidade no corpus. A expressão não explica os dados de treinamento nem demonstra causalidade. Ela só será usada na discussão se houver convergência entre CLIP, baseline humana e composição facial.

Metodologia

3.1 Natureza e delineamento da pesquisa

Esta é uma pesquisa aplicada, de abordagem quantitativa e objetivo exploratório. O delineamento é comparativo. O artefato computacional analisa imagens produzidas sob duas condições de *prompt*, sem buscar relações causais internas aos modelos geradores.

3.2 Corpus, manifesto e baseline humana

O corpus original contém 64 imagens: oito cenários, duas variantes de *prompt* e quatro modelos geradores. As imagens e as avaliações humanas foram produzidas no estudo de [Silva et al. \(2026\)](#). Dois avaliadores atribuíram notas de um a cinco para diversidade racial, representação de gênero, adequação cultural, representação corporal e qualidade visual.

O pipeline também aceita outros conjuntos de imagens. A busca percorre recursivamente o diretório de entrada e não interpreta a posição das pastas. Um manifesto opcional associa o caminho relativo a modelo gerador, tipo de *prompt*, cenário e par comparável. Sem esses metadados, as imagens são processadas, mas os testes inferenciais são ignorados.

Antes da inferência neural, cada arquivo é validado com Pillow. O sistema não segue links simbólicos, não reprocessa o diretório de saída e calcula o SHA-256 do conteúdo. Duplicatas são rejeitadas por padrão. O identificador `imagem_id` deriva do identificador do dataset e desse hash, permanecendo estável quando a imagem apenas muda de pasta.

3.3 Ambiente e fluxo de execução

O notebook oficial funciona como orquestrador do pacote `biasauditfw`. Ele é executado no Google Colab com GPU NVIDIA T4, monta o Google Drive, registra versões e roda

os testes determinísticos antes dos modelos neurais. Um teste inicial processa quatro imagens; a execução completa é ativada depois da verificação desses artefatos.

O schema 2.0 possui duas unidades. `audit_images.csv` registra uma linha por imagem, com metadados, número de faces e escores CLIP. `audit_faces.csv` registra uma linha por rosto, com caixa delimitadora e predições de atributos. Os escores CLIP não aparecem na tabela facial.

3.4 Detecção e predição de atributos

RetinaFace localiza as regiões faciais e DeepFace produz predições de raça e gênero (SERENGIL; OZPINAR, 2026). O pipeline percorre toda a lista retornada. Uma imagem pode gerar zero, uma ou várias linhas faciais. Quando nenhuma face válida é encontrada, a imagem permanece na tabela de imagens com `num_faces = 0`.

As caixas são ordenadas por posição vertical e horizontal antes da atribuição de `face_id`. Origens negativas são limitadas a zero e caixas sem largura ou altura são descartadas. As categorias resultantes descrevem sinais visuais percebidos em faces sintéticas. Elas não informam identidade, nacionalidade, ancestralidade, miscigenação ou sexo biológico.

3.5 Escores de diversidade com CLIP

O CLIP recebe a imagem completa e doze frases, distribuídas em quatro famílias. As formulações são mantidas em inglês para corresponder ao código:

- diversidade racial: *a racially diverse group of people; people with diverse racial appearances; a group with varied skin tones and racialized appearances;*
- homogeneidade racial: *a racially homogeneous group of people; people with similar racial appearances; a group with little variation in racialized appearance;*
- diversidade de apresentação de gênero: *a gender-diverse group of people; people with diverse gender presentation; a group with varied masculine, feminine, and androgynous presentation;*
- homogeneidade de apresentação de gênero: *a gender-homogeneous group of people; people with similar gender presentation; a group with one visually similar gender presentation.*

Seja $\mathcal{A}_k$ o conjunto de frases da família k . Cada vetor textual é normalizado pela norma Euclidiana. Em seguida, os vetores da família são promediados e o protótipo resultante é normalizado novamente:

$$\hat{t}_j = \frac{f_T(T_j)}{\|f_T(T_j)\|_2}, \quad \vec{p}_k = \frac{\frac{1}{|\mathcal{A}_k|} \sum_{T_j \in \mathcal{A}_k} \hat{t}_j}{\left\| \frac{1}{|\mathcal{A}_k|} \sum_{T_j \in \mathcal{A}_k} \hat{t}_j \right\|_2}. \quad (3.1)$$

O vetor da imagem também é normalizado:

$$\hat{z}_I = \frac{f_I(I)}{\|f_I(I)\|_2}. \quad (3.2)$$

A similaridade com um protótipo é o produto escalar entre vetores unitários:

$$S_C(I, k) = \hat{z}_I \cdot \vec{p}_k. \quad (3.3)$$

Cada cosseno pertence a $[-1, 1]$. As duas margens são calculadas de forma independente:

$$M_r(I) = S_C(I, D_r) - S_C(I, H_r), \quad (3.4)$$

$$M_g(I) = S_C(I, D_g) - S_C(I, H_g), \quad (3.5)$$

em que D_r e H_r representam os protótipos raciais de diversidade e homogeneidade, enquanto D_g e H_g representam os protótipos de apresentação de gênero. Ambas as margens pertencem ao intervalo teórico $[-2, 2]$. O método não aplica *softmax*, não combina as margens e não usa CLIP para contar pessoas. Os valores expressam alinhamento semântico com os protótipos e são calculados uma vez por imagem.

3.6 Ground Truth da detecção facial

Dois avaliadores anotam independentemente as caixas faciais em formato COCO. Diferenças de contagem, regiões sem par ou pares com interseção sobre união (IoU) inferior a 0,5 são resolvidos por consenso. As imagens do COCO são associadas por caminho relativo ou por identificador de origem, evitando colisões entre arquivos com o mesmo nome.

As predições de RetinaFace são pareadas às caixas do consenso por correspondência um-para-um. Uma predição é verdadeiro positivo quando $\text{IoU} \geq 0,5$. O relatório inclui precisão, revocação, F1, IoU média, falsos positivos e falsos negativos. Intervalos de confiança são estimados por *bootstrap* no nível da imagem.

3.7 Baseline humana e pseudo-oráculo

As notas R1 e R2 de diversidade racial e representação de gênero são preservadas separadamente. A concordância ordinal é medida pelo kappa ponderado. A média dos avaliadores é correlacionada, por Spearman, com a margem CLIP correspondente.

FairFace é executado nos recortes definidos pelo Ground Truth (KARKKAINEN; JOO, 2021). As taxonomias são harmonizadas apenas quando há correspondência explícita. A comparação com DeepFace informa acordo, kappa de Cohen, macro-F1 e matriz de confusão. FairFace é uma referência operacional, não um rótulo verdadeiro.

Como evidência convergente secundária, o sistema calcula índices de Simpson normalizados sobre as categorias faciais por imagem. Imagens com menos de dois rostos recebem valor ausente, pois não há diversidade intragrupo observável.

3.8 Análise estatística

Mann–Whitney compara *prompts* inclusivos e neutros separadamente para M_r e M_g , com $\alpha = 0,05$. A entrada possui uma linha por imagem. O relatório apresenta tamanhos dos grupos, medianas, intervalos interquartis, estatística U, *p-value* e correlação bisserial de postos. A correção de Holm cobre as duas hipóteses primárias.

Wilcoxon é usado como análise de sensibilidade pareada por modelo e cenário. Comparações exploratórias separadas por modelo recebem outra correção de Holm, aplicada à família completa. Quando $p \geq 0,05$, o texto informa que não há evidência suficiente para rejeitar a hipótese nula.

3.9 Reprodutibilidade e artefatos

O notebook exporta as tabelas canônicas, um relatório de ingestão, metadados da execução, estatísticas e gráficos. Um validador independente confere o schema e recalcula os testes a partir dos CSVs. O Streamlit consome esses arquivos sem executar novamente os modelos neurais e aplica filtros de modelo às duas tabelas por meio de `imagem_id`.

Resultados e discussão

Este capítulo está preparado para receber os artefatos schema 2.0 da execução final no Google Colab. Os resultados anteriores foram preservados como legado, mas não são usados aqui porque pertencem ao antigo eixo semântico. Inserir números antes da nova execução misturaria métodos diferentes.

4.1 Cobertura e integridade do corpus

A análise final informará o número de imagens válidas, duplicatas rejeitadas, erros de leitura, total de faces e proporção de imagens sem detecção. Para o corpus original, o primeiro critério de aceite é obter 64 identificadores únicos. A soma de `num_faces` deverá coincidir com o número de linhas de `audit_faces.csv`.

4.2 Desempenho do detector

Serão apresentados precisão, revocação, F1, IoU média, falsos positivos e falsos negativos, tanto no conjunto completo quanto por modelo e tipo de *prompt*. Esses valores responderão se RetinaFace localizou as regiões anotadas pelos avaliadores. Um desempenho baixo será reportado como resultado do método, não ocultado por um limiar de aprovação escolhido depois da execução.

4.3 Baseline humana e pseudo-oráculo

O kappa ponderado descreverá a concordância entre R1 e R2 para diversidade racial e representação de gênero. Cada média humana será correlacionada com sua margem CLIP por Spearman. A concordância entre DeepFace e FairFace será apresentada separadamente para raça e gênero, sem ser interpretada como acurácia de identidade.

4.4 Composição facial

As distribuições de categorias raciais e de gênero serão calculadas a partir de `audit_faces.csv`. Tabelas e gráficos indicarão que a unidade observacional é o rosto detectado. Os índices de Simpson servirão apenas como evidência complementar e permanecerão ausentes em imagens com menos de duas faces.

4.5 Diversidade semântica no nível da imagem

Os quatro cossenos e as duas margens serão descritos por tipo de *prompt* e modelo. A unidade observacional será a imagem. A relação com a baseline humana ajudará a avaliar a validade convergente de cada dimensão; correlação fraca ou ausente limitará a interpretação dos escores CLIP.

4.6 Comparação entre prompts

Para cada margem, o resultado principal apresentará U , p -value, p -value corrigido por Holm, tamanho dos grupos, medianas, intervalos interquartis e correlação bisserial de postos. Se $p \geq 0,05$, será usada a formulação “não se rejeita H_0 ”. Wilcoxon e as comparações por modelo serão discutidos como análises complementares, sem substituir o resultado primário.

4.7 Efeito Patchwork e ameaças à validade

O Efeito Patchwork somente será discutido se houver inclusão visual pontual sem aumento consistente das margens e se esse padrão também aparecer na baseline humana e na composição facial. A interpretação deverá considerar o tamanho do corpus, a formulação dos protótipos, as limitações de contagem do CLIP, cenas com várias pessoas, erros de detecção, divergência entre classificadores e subjetividade das avaliações humanas.

Conclusão

O trabalho desenvolve um procedimento que separa métricas por imagem e por rosto, aceita estruturas de diretório arbitrárias e registra as condições da execução. Essa divisão evita repetir um mesmo score CLIP conforme o número de faces detectadas. O pipeline também inclui meios de avaliar o detector e comparar as saídas automáticas com referências humanas e computacionais.

A conclusão empírica será finalizada depois da nova execução das 64 imagens e da consolidação do Ground Truth. Até essa etapa, não é possível afirmar se os *prompts* inclusivos alteram as margens de diversidade racial percebida e de apresentação de gênero, nem se as evidências sustentam o Efeito Patchwork.

Os limites permanecem centrais para a leitura dos resultados. DeepFace e FairFace classificam aparências em faces sintéticas, enquanto CLIP mede alinhamento semântico com frases escolhidas pelo pesquisador. Nenhuma dessas ferramentas determina identidade demográfica. O *framework* contribui ao registrar essas restrições junto com os resultados e ao tornar verificável o caminho entre imagem, medida e conclusão.

Referências Bibliográficas

BIANCHI, F. et al. *Demographic Stereotypes in Text-to-Image Generation*. [S.l.], 2023. Disponível em: <https://hai.stanford.edu/policy-brief-demographic-stereotypes-text-image-generation>.

BIRHANE, A.; PRABHU, V. U.; KAHEMBWE, E. Multimodal datasets: misogyny, pornography, and malignant stereotypes. *arXiv preprint arXiv:2110.01963*, 2021. Disponível em: <https://arxiv.org/abs/2110.01963>.

HALL, M. et al. Towards geographic inclusion in the evaluation of text-to-image models. In: *Proceedings of the 2024 ACM Conference on Fairness, Accountability, and Transparency (FAccT '24)*. [s.n.], 2024. p. 588–605. Disponível em: <https://doi.org/10.1145/3630106.3658933>.

Instituto Brasileiro de Geografia e Estatística. *Censo Demográfico 2022: População por Cor ou Raça, Resultados do Universo*. Rio de Janeiro, 2023. Disponível em: <https://sidra.ibge.gov.br/pesquisa/censo-demografico/demografico-2022/universo-populacao-por-cor-ou-raca>. Acesso em: 11 jul. 2026.

KARKKAINEN, K.; JOO, J. Fairface: Face attribute dataset for balanced race, gender, and age for bias measurement and mitigation. In: *Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision*. [s.n.], 2021. p. 1548–1558. Disponível em: https://openaccess.thecvf.com/content/WACV2021/html/Karkkainen_FairFace_Face_Attribute_Dataset_for_Balanced_Race_Gender_and_Age_WACV_2021_paper.html.

LYU, Y. et al. Do existing testing tools really uncover gender bias in text-to-image models? In: *Proceedings of the 33rd ACM SIGSOFT International Symposium on Software Testing and Analysis*. Association for Computing Machinery, 2025. Disponível em: <https://dl.acm.org/doi/10.1145/3746027.3755748>.

MIM, N. J. et al. In-between visuals and visible: The impacts of text-to-image generative ai tools on digital image-making practices in the global south. In: *Proceedings of the CHI Conference on Human Factors in Computing Systems*. [s.n.], 2024. Disponível em: <https://doi.org/10.1145/3613904.3642453>.

PAISS, R. et al. Teaching clip to count to ten. In: *Proceedings of the IEEE/CVF International Conference on Computer Vision*. [s.n.], 2023. p. 3170–3180. Disponível em: https://openaccess.thecvf.com/content/ICCV2023/html/Paiss_Teaching_CLIP_to_Count_to_Ten_ICCV_2023_paper.html.

RADFORD, A. et al. Learning transferable visual models from natural language supervision. In: PMLR. *International Conference on Machine Learning*. 2021. p. 8748–8763. Disponível em: <<https://arxiv.org/abs/2103.00020>>.

REGE, A. et al. Cure: Cultural gaps in the long tail of text-to-image systems. In: *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*. [s.n.], 2025. Disponível em: <https://openaccess.thecvf.com/content/ICCV2025/papers/Rege_CuRe_Cultural_Gaps_in_the_Long_Tail_of_Text-to-Image_Systems_ICCV_2025_paper.pdf>.

SAHILI, Z. A.; PATRAS, I.; PURVER, M. Data matters most: Auditing social bias in contrastive vision-language models. *Transactions on Machine Learning Research*, 2025. Disponível em: <<https://openreview.net/forum?id=3vF2fn9owm>>.

SCHNEIDER, M.; HAGENDORFF, T. Investigating toxicity and bias in stable diffusion text-to-image models. *Scientific Reports*, Nature Publishing Group, v. 15, n. 31401, 2025.

SERENGIL, S. I.; OZPINAR, A. Boosted lightface: A hybrid dnn and gbm model for boosted facial recognition. *Gazi University Journal of Science*, Gazi University, v. 39, n. 1, p. 452–466, 2026. Disponível em: <<https://dergipark.org.tr/en/pub/gujs/article/1794891>>.

SILVA, K. H. et al. Exploring bias in ai-generated imagery: A design-research case study in university visual communication. In: *INTED2026 Proceedings*. IATED, 2026. (20th International Technology, Education and Development Conference), p. 2311. ISBN 978-84-09-82385-7. ISSN 2340-1079. Disponível em: <<https://doi.org/10.21125/inted.2026.2311>>.

VICE, J. et al. Quantifying bias in text-to-image generative models. *IEEE Transactions on Dependable and Secure Computing*, PP, p. 1–14, 01 2025.

ZHANG, L. et al. Partiality and misconception: Investigating cultural representativeness in text-to-image models. In: *Proceedings of the CHI Conference on Human Factors in Computing Systems*. ACM, 2024. Disponível em: <<https://doi.org/10.1145/3613904.3642877>>.